

AUDIT INFRASTRUTTURALE PROFESSIONALE

La Migliore Infrastruttura per Obiriec Labs

Versione: Maggio 2026 · Scope: DELULUREEL · AVARCAST · Ecosistema fal.ai · Podcast ·

Revisione: Aprile 2027

7

Provider cloud analizzati

20+

Modelli AI catalogati

74%

Margine infra a 10K utenti

€0

Egress video con R2



Executive Summary

Raccomandazioni immediate e visione strategica



Raccomandazione principale: migrare da Render Starter a **Fly.io** (rolling deploy nativi, macchine persistenti, 4GB RAM a \$24/mese) con **Celery + Upstash Redis** per job queue e **Cloudflare R2** per storage video. fal.ai rimane il provider AI video — nessun concorrente offre qualità/prezzo comparabile nel 2026.



Problema attuale su Render Starter: 512MB RAM insufficienti per FFmpeg + librosa + Python. Deploy = kill immediato di tutti i thread in-flight. Cold start 1–3 min. Inaccettabile per SaaS con 1.000+ utenti paganti.

Web Server

Fly.io shared-cpu-4x

4GB RAM · Rolling deploy nativi · 2 repliche · \$24/mese · Regione AMS (latenza IT <15ms). Nessun job in-flight killato durante i deploy.

Worker Video

Fly.io performance-2x

CPU dedicata per FFmpeg · 4GB RAM · Autoscale 0–3 macchine · \$64/mese base. Isolato dal web server, mai interrotto dai deploy.

Job Queue

Celery + Upstash Redis

Serverless Redis · 500K cmd/mese gratis · Python nativo · Retry automatico · Monitoring Flower incluso.

Storage Video

Cloudflare R2

Egress \$0 · S3-compatible · A 10K utenti risparmio \$120K+/anno vs AWS S3 · CDN globale via CF Workers.

AI Video

fal.ai — Kling v3 Pro

Migliore qualità/prezzo 2026 · Audio nativo incluso · 4K disponibile · 99.99% SLA · 600+ modelli con singola API key.

Avatar (AVARCAST)

fal.ai + ElevenLabs

Omnihuman/SadTalker per animazione · Voice clone ElevenLabs · Lipsync fal.ai Sync · Costo 5–10x inferiore a HeyGen/Synthesia.

A

Cloud Hosting per Flask + Job Video

Confronto 7 provider — criteri: rolling deploy, RAM, FFmpeg, costo EU

PROVIDER	PIANO	RAM	€/MESE	ROLLING DEPLOY	AFFIDAB
★ Fly.io	shared-cpu-4x	4 GB	\$24	Nativo	9
★ Fly.io	performance-2x	4 GB	\$64	Nativo	9
Railway	Pro (usage)	8 GB max	\$5-20+	Sì	8
Hetzner CX42	VPS Dedicato	16 GB	€16.40	Manuale	7
DigitalOcean	Basic 4GB	4 GB	\$24	App Platform	8
Modal.com	Serverless GPU	variabile	\$0.04/GPU-h	Stateless	9
Google Cloud Run	2vCPU/4GB	4 GB	\$0-60	Sì	9
Render Standard	Standard (attuale)	2 GB	\$25	Kill in-flight	5



Nota critica su Render: i deploy killano i thread in-flight senza graceful shutdown. Nessun piano Render risolve questo a livello architetturale — è un limite del loro sistema di deploy. Fly.io ha rolling deploy nativi con health check per container: il container vecchio rimane attivo finché quello nuovo è pronto e supera tutti i check.



Background Job Processing

Gestione asincrona FFmpeg, librosa, chiamate AI

SISTEMA	TIPO	COSTO/MESE	AFFIDABILITÀ	RETRY AUTO	PYTHON
★ Celery + Upstash Redis	Self-managed	\$0 (free tier)	Alta	✓ Nativo	✓ Nativo
Inngest	Managed	\$0–usage	Alta	✓ Built-in	✓ SDK
Modal.com Functions	Serverless	\$30 free/mese	Altissima	✓ Nativo	✓ SDK
AWS SQS + Lambda	Cloud managed	~\$1–10	Altissima	✓ DLQ	✓ boto3
Render Background Worker	PaaS	\$25/mese	Media	✗ No	✓



Storage & CDN per Video

Costi reali su 10.000 video MP4 da 30MB (300GB storage, 1.5TB egress/mese)

PROVIDER	STORAGE /GB/MESE	EGRESS /GB	CDN	COSTO 300GB + 1.5TB
★ Cloudflare R2	\$0.015	\$0.00	✓ Workers/r2.dev	\$4.50
Bunny.net Stream	\$0.01	\$0.005	✓ + Player	\$10.50
Supabase Pro	\$0.021	\$0.03 (over 250GB)	✓ Smart CDN	~\$0* (incluso)
Backblaze B2 + CF	\$0.006	\$0 (via CF)	✓ via CF	\$1.80
AWS S3 + CloudFront	\$0.023	\$0.085 (EU)	✓ CloudFront	\$134.40



Risparmio Cloudflare R2 vs AWS S3: a 10.000 utenti attivi e 1.5TB di egress mensile, R2 costa \$4.50/mese contro \$134.40 di S3+CloudFront. Risparmio annuo: ~\$1.560. A 100.000 utenti: risparmio annuo ~\$156.000.



fal.ai — Catalogo Modelli Strategici

Video · Immagini · Avatar · Audio · TTS — singola API key per 600+ modelli

Video Generation

Avatar / Talking Head

Audio / Music

Image Generation

MODELLO	TIPO	PREZZO	DURATA	QUALITÀ	USE CASE OBIRIEC
★ Kling v3 Pro	I2V	\$0.112/sec	5s / 10s	★★★★★	DELULUREEL tier Pro — coerenza visiva + audio nativo
★ Seedance 2.0	I2V / T2V	\$0.05–0.08/sec	5s / 10s	★★★★★	Alternativa cinema-grade con audio nativo incluso
Kling v2.6 Pro	I2V	\$0.07/sec	5s / 10s	★★★★★	Rapporto qualità/prezzo ottimale — tier Standard
Kling 3.0 4K Native	I2V	Premium	5s	★★★★★	DELULUREEL tier Ultra (futuro)
Wan 2.5	T2V	\$0.05/sec	variabile	★★★★★	Open source — buon prezzo per volumetria alta
Veo 3 (Google)	T2V	\$0.40/sec	variabile	★★★★★	Qualità massima — tier premium AVARCAST broadcast



Alternative & Complementi a fal.ai

Provider da integrare o monitorare nell'ecosistema Obiriec


PROVIDER	MODELLI CHIAVE	API PUBBLICA	PRICING	QUALITÀ	STRENGTH
Runway ML	Gen-4 Turbo, Gen-4 Aleph	Si	\$0.05–0.15/sec	★★★★★	Caratteristiche avanzate AVA
ElevenLabs	Voice Clone, TTS, Music	Si (integrato)	\$0.06–0.12/1000 char	★★★★★	Già nell'OL voice ava
Replicate	Modelli community + custom	Si	\$0.000115/sec CPU	★★★★★	Fallimento Cog
Stability AI	SDXL, Stable Audio	Si	~\$0.04/immagine	★★★★★	Immagini sforzami
Suno AI	Music generation completa	No API pubblica	N/A	★★★★★	Solo (UI) Mo ape 202
Udio	Music generation	Beta limitata	TBD	★★★★★	Da per intere futu



Architettura DELULUREEL — Target

Stack completo per 1.000–100.000 utenti





Componenti stack

DNS/CDN: Cloudflare (già attivo)

App: Fly.io shared-cpu-4x · \$24/mese

Worker: Fly.io performance-2x · \$64/mese

Queue: Celery + Upstash Redis · \$0

Storage: Cloudflare R2 · \$0.015/GB

DB/Auth: Supabase Pro · \$25/mese

AI: fal.ai Kling v3 + MMAudio V2

Pagamenti: Stripe (già attivo)

Vantaggi vs Render attuale

- ✓ Rolling deploy — nessun job killato
- ✓ 4GB RAM — FFmpeg senza OOM
- ✓ Worker isolato — deploy web ≠ kill job
- ✓ Celery retry — job resistenti ai crash
- ✓ R2 egress \$0 — costi video scalano
- ✓ Autoscale worker — 0 costo in idle



Architettura AVARCAST

"Your avatar. Your broadcast." — Layer aggiuntivo su base DELULUREEL



Avatar Layer

fal.ai Omnihuman v1.5 — animazione avatar da foto

ElevenLabs — voice clone 30sec campione → TTS

fal.ai Sync Lipsync v3 — lip sync avatar + voce

Runway ML Gen-4 — camera controls broadcast



Broadcast Layer

Bunny.net Stream — video hosting HLS + player

\$0.005/GB delivery · Player gratuito incluso

Cloudflare Stream (alt.) — \$5/1.000 min Embed iframe su qualsiasi piattaforma



Costo stimato (100 utenti)

Base DELULUREEL: \$160/mese

ElevenLabs Creator: \$22/mese

Avatar gen (setup): \$5–15/utente one-time

Bunny Stream CDN: ~\$20/mese

Totale: ~\$300–400/mese

Modello pricing: abbonamento mensile



Setup Personale — Podcast & Content

Pipeline broadcast-grade senza studio fisico · \$70/mese totale



Audio Enhancement

Adobe Podcast Premium — €9.99/mese.
Riduzione rumore broadcast-grade.
Trasforma qualsiasi registrazione (anche AirPods) in audio studio. Nessun hardware aggiuntivo necessario.



Editing & Clip Social

Descript Creator — \$24/mese. Edit testo-based (cancelli le parole, sparisce il silenzio). Genera automaticamente 3–5 clip social da ogni episodio. Trascrizione automatica.



AI Voiceover

ElevenLabs (già attivo) — Clone voce personale · TTS per episodi senza mic.
Creator plan \$22/mese include 100K char
→ 3–4 episodi da 30 min.



Video Montaggio

DaVinci Resolve — €0 (già installato).
Color grade · Audio mix finale · Export ottimizzato per Spotify Video + YouTube.



Pipeline completa: Registrazione → Adobe Podcast Enhance → Logic Pro (mix) → Descript (edit + clip) → DaVinci Resolve (color) → Buffer (\$15/mese) per scheduling multi-piattaforma. Costo totale: **\$70/mese**.



Calcolatore Costi Infrastruttura

Stima in tempo reale basata su utenti e video mensili



Parametri

Utenti attivi/mese

1000

Video generati/mese

2000

Durata media clip (sec)

8

Revenue per video (€)

2,50

\$2046

Costo infra/mese

€5000

Revenue target/mese

59%

Margine netto infra

Fly.io App: \$96 · Worker: \$128 · Redis: \$4 · R2: \$1 · Supabase: \$25 · fal.ai: \$1792



Roadmap Implementazione

Priorità, timeline e effort per ogni fase

1

Migrazione Fly.io + Celery **URGENTE**

🕒 5 giorni 💰 \$0 costo setup 🎯 Elimina crash al 99%

Fly.io launch dal repo esistente · macchina worker separata · Celery + Upstash Redis · Cloudflare R2 per video · Rolling deploy verificato con test. Nessuna modifica alla logica applicativa.

2

Prompt con Claude Vision + Polling fal.ai **ALTA**

🕒 3 giorni 💰 +\$0.02/video 🎯 Qualità video da ★★ a ★★★★★

Analisi foto con Claude Vision prima di generare il prompt Kling → prompt contestuale alla scena reale. Polling ogni 5 secondi invece di webhook → zero dipendenza da uptime server. Questi due fix cambiano radicalmente la qualità e affidabilità percepita.

3

fal.ai MMAudio V2 — Audio Sync Automatico **ALTA**

🕒 2 giorni 💰 +\$0.05/video 🎯 Differenziatore competitivo chiave

MMAudio V2 genera audio ambientale sincronizzato al video generato da Kling. Il reel finale ha: musica utente (sync) + audio ambiente AI (sottofondo). Nessun competitor standard offre questa pipeline automatica.

4

AVARCAST MVP **MEDIA**

🕒 3-4 settimane 💰 ~\$200 test API 🎯 Nuovo verticale prodotto

Avatar parlante da foto + ElevenLabs voice clone + Sync Lipsync. Distribuzione via Bunny Stream. Modello abbonamento mensile con crediti broadcast inclusi.

5

Setup Podcast Personale **BASSA**

🕒 1 giorno 💰 \$70/mese ongoing 🎯 Presenza personale broadcast-grade

Adobe Podcast Premium + Descript Creator + Buffer. Workflow completo: registra → enhance → clip → schedula su 5 piattaforme in 30 minuti.





Sintesi Decisioni Chiave

Ogni scelta con motivazione e alternativa scartata

DECISIONE	SCELTA	ALTERNATIVA SCARTATA	MOTIVAZIONE
Cloud host	Fly.io	Render / Railway	Rolling deploy nativi. Nessun kill job. EU <20ms.
Storage video	Cloudflare R2	AWS S3	Egress \$0. A 10K utenti: -\$1.560/anno vs S3.
Job queue	Celery + Upstash Redis	Render Background Worker	Python nativo. Serverless Redis gratis. Retry automatico.
AI video (primario)	fal.ai Kling v3 Pro	Veo 3 / Runway diretto	Qualità/prezzo imbattibile. Audio nativo. 4K disponibile.
AI audio sync	fal.ai MMAudio V2	FFmpeg puro	Audio AI contestuale al video — differenziatore prodotto.
Avatar AVARCAST	fal.ai + ElevenLabs	HeyGen / Synthesia	Controllo API totale. Costo 5–10x inferiore. Ecosistema già integrato.
Podcast	Adobe Podcast + Descript	Riverside.fm	Adobe gratis per base. Descript superiore per clip social automatici.



Risk da monitorare: fal.ai ha modificato i prezzi 3–4 volte negli ultimi 12 mesi. Implementare un *model router* che permetta di cambiare modello senza toccare il codice applicativo. Tenere Replicate come fallback per i modelli critici. A \$15K/mese di spend su fal.ai, aprire trattative per contratto enterprise con sconto 20–30%.

OBIRIEC LABS

Audit Infrastrutturale Professionale · Maggio 2026

Preparato da Claude Sonnet · Revisione annuale: Aprile 2027



Stampa / Salva PDF